

## INSTITUTO FEDERAL DE EDUCAÇÃO CIÊNCIA E TECNOLOGIA DA PARAÍBA CAMPUS ESPERANÇA

Trabalho 01 - Alan Mateus, Lucas Rickelme, Pedro Henrique Gregório e Sabrina Costa.

Nenad Petrovic et al. apresentam o artigo “LLM-Driven Testing for Autonomous Driving Scenarios”, publicado na 2ª Conferência Internacional sobre Fundamentos e Modelos de Linguagem de Grande Escala (FLLM2024). O trabalho aborda temas como direção autônoma, CARLA, GPT, LLM e Llama3, e analisa a complexidade e os custos elevados dos testes, principalmente relacionados a sua execução, planejamento e padronização, em sistemas autônomos. A fim de mitigar essa problemática, os autores sugerem a utilização de LLMs para automatizar a criação dos testes e acelerar o desenvolvimento e reduzir a intervenção manual.

Na introdução, destaca-se o crescimento da inteligência artificial nos últimos anos, junto ao avanço das técnicas de visão computacional e análise de dados, que abrem novas oportunidades de inovação. Contudo, o setor automotivo enfrenta desafios devido aos rigorosos processos de padronização, conformidade e testes realizados manualmente, os quais retardam a incorporação de inovações. Assim, a problemática central é a necessidade de métodos mais eficientes para a geração de testes, e o objetivo do artigo é explorar como os LLMs podem solucionar o problema proposto.

A revisão da literatura evidencia o grande potencial dos LLMs na automação de testes, focando principalmente em ferramentas como o ChatUnitTest. Entretanto, a maioria das soluções concentra-se em testes unitários. Bem como, os testes automáticos referentes a área automobilística, podem até utilizar de alguns modelos para realizar testes em cenários específicos, mas não abordaram o uso das LLMs para automatizar esses processos, como também da possibilidade de integrar esses testes como um sistema.

Na implementação, os autores descrevem um fluxo de trabalho inovador baseado em LLMs. Inicialmente, regras e instâncias de modelos, formados por uma série de funções que resgatam informações geradas a partir de um metamodelo (Ecore) e convertidas em uma configuração JSON para o simulador CARLA. Esse fluxo, que integra verificações em tempo de design com feedback em tempo de execução, divide-se em dois subtópicos: a cadeia de geração de testes e o modelo do experimento automotivo, que define a configuração dos veículos, do ambiente e da cadeia de eventos. O caso de uso exemplifica um cenário de freio de emergência, com um Tesla Model 3 (ego) e um Toyota Prius (líder) interagindo em condições simuladas. Estas condições foram elaboradas para testar se o carro ego poderia conseguir frear sem que haja a colisão em outro carro ou pedestre.

Paralelamente, o artigo dá detalhes sobre a construção de um metamodelo chamado Automotive Experiment Topology (AET), que organiza as configurações para testes, como ambiente, veículos, sensores, cadeia de eventos e atuadores, permitindo a construção de cenários complexos e próximos ao trânsito real. Esse metamodelo serve como base para que as LLMs gerem as configurações para o simulador CARLA.

Ademais, os autores estruturam um conjunto de prompts responsáveis por guiar a geração de teste automáticos a fim de evitar erros e tornar o desenvolvimento mais rápido e eficiente. Esses prompts passam por 5 etapas como a conversão dos requisitos em regras de negócio, em seguida passa pela criação do modelo e por fim gera os arquivos que passaram a ser utilizados no CARLA, além disso, também há comandos que geram feedbacks durante o tempo de execução.

Na seção de experimentos, a comparação entre GPT-4 e Llama3 revela que o GPT-4 possui tempos de resposta significativamente mais rápidos, com taxa de erros 10% menor, e menor consumo de tokens, comparado ao modelo local. Enquanto o Llama3 se destaca pela possibilidade de implantação local. A abordagem reduziu o tempo de geração de testes em mais de dez vezes. Os autores ainda enfatizam que o uso de LLMs tanto aceleram a geração de testes como facilita o trabalho dos desenvolvedores tendo em vista que modelos open source podem ser ajustados por cada empresa para seu uso direcionado.

Por conseguinte, a conclusão ressalta o potencial revolucionário dos LLMs para automatizar testes em sistemas automotivos e aponta para futuras pesquisas, como a integração com bancadas de testes de veículos reais, visando maior eficiência e redução de custos, além de mencionar o refinamento do uso de modelos locais com técnicas como fine-tuning para ajudar a realizar ajustes pontuais em todas as etapas de execução. Além disso, os autores deixam em aberto o desejo de aplicarem o uso prático dos seus estudos e integrarem a solução em veículos reais.